Vilniaus Universitetas

Dimensijos mažinimas klasterizavime

Darbą atliko:

Vainius Gataveckas, Matas Gaulia, Dovydas Martinkus

Duomenų Mokslas

3 kursas 2 gr.

Vilnius, 2022

Turinys

1 Tikslas ir uždaviniai 3
2 Duomenų aibė 4
3 Atliktos analizės aprašymas 5
3.1 Pradinis apdorojimas 5
3.2 Klasterizavimas k-means metodu 6
3.3 Klasterizavimas $DBSCAN$ metodu 16
3.4 Klasterizavimas hierarchiniu metodu 18
4 Išvados 20
5 Šaltiniai 21
Priedas 22

1 Tikslas ir uždaviniai

Tikslas: Išskirti tiriamoje duomenų aibėje klasterius bei apibrėžti susidariusių klasterių specifiką.

Uždaviniai:

Pasirinkti duomenų aibę klasterizavimui.

Pasirinkti, pagal kokius požymių rinkinius bus atliekamas klasterizavimas.

Įvertinti optimalų klasterių skaičių ir suklasterizuoti duomenis naudojantis skirtingais klasteriavimo algoritmais.

Suklasterizuoti ir vizualizuoti duomenis, gautus panaudojus dimensijos mažinimo algorimus.

Pateikti susidariusių klasterių aprašomasias statistikas ir palyginti kas pasikeitė klasterizavus originalius duomenis, ir sumažinus dimensiją

Rasti kokios tendencijos būdingos kiekvienam klasteriui ir kuo vienas klasteris skiriasi nuo kito.

2 Duomenų aibė

Spotify Past Decades Songs duomenų aibė

Duomenų aibės šaltinis: Kaggle

Nuoroda per internetą: https://www.kaggle.com/cnic92/spotify-past-decades-songs-50s10s?select=1990.csv

Duomenų aibę sudaro tokie požymiai:

„Number“ – (kategorinis, nominalusis) dainą identifikuojantis kodas

„Title“ – (kategorinis, nominalusis) dainos pavadinimas

„Artist“ – (kategorinis, nominalusis) atlikėjas arba grupė

„Top Genre“ – (kategorinis, nominalusis) dainos žanras

„Year“ – (kiekybinis, diskretusis, intervalinė skalė) išleidimo metai

„Decade“ – (kiekybinis, diskretusis, intervalinė skalė) išleidimo dešimtmetis

„Tempo“ – (kiekybinis, tolydus, santykių skalė) dainos tempas

“Loudness (dB)“ - (kiekybinis, tolydus, intervalų skalė) dainos garsumas

„Duration“ – (kiekybinis, tolydus, santykių skalė) dainos trukmė

„Energy“ – (kiekybinis, tolydus, santykių skalė) dainos energija

„Danceability“ – (kiekybinis, tolydus, santykių skalė) lengvumas šokti pagal dainą

„Liveness“ – (kiekybinis, tolydus, santykių skalė) kaip tikėtina, kad daina yra gyvas įrašas

„Valence“ – (kiekybinis, tolydus, santykių skalė) dainos pozityvumas

„Acousticness“ – (kiekybinis, tolydus, santykių skalė) dainos akustiškumas

„Speechiness“ – (kiekybinis, tolydus, santykių skalė) kiek dainoje yra kalbama

„Popularity“ - (kiekybinis, tolydus, santykių skalė) dainos populiarumas pagal perklausų skaičių

3 Atliktos analizės aprašymas

3.1 Pradinis apdorojimas

Duomenų aibę pasirinkta klasterizuoti pagal visus skaitinius požymius („Tempo“, „Loudness“, „Duration“, „Energy“, „Danceability“, „Liveness“, „Valence“, „Acousticness“, „Speechiness“, „Popularity“ n=10).

Visų skaitinių požymių matavimo skalės suvienodintos standartizuojant juos pagal vidurkį ir dispersiją.

Siekiant palyginti klasterizavimo rezultatus naudojant dimensijos mažinimo metodus ir jų nenaudojant, duomenų aibės požymių dimensija sumažinta iki 2 naudojantis pagrindinių komponenčių analizės (angl. principal component analysis, toliau - PCA) metodu (žr. 1 pav.).

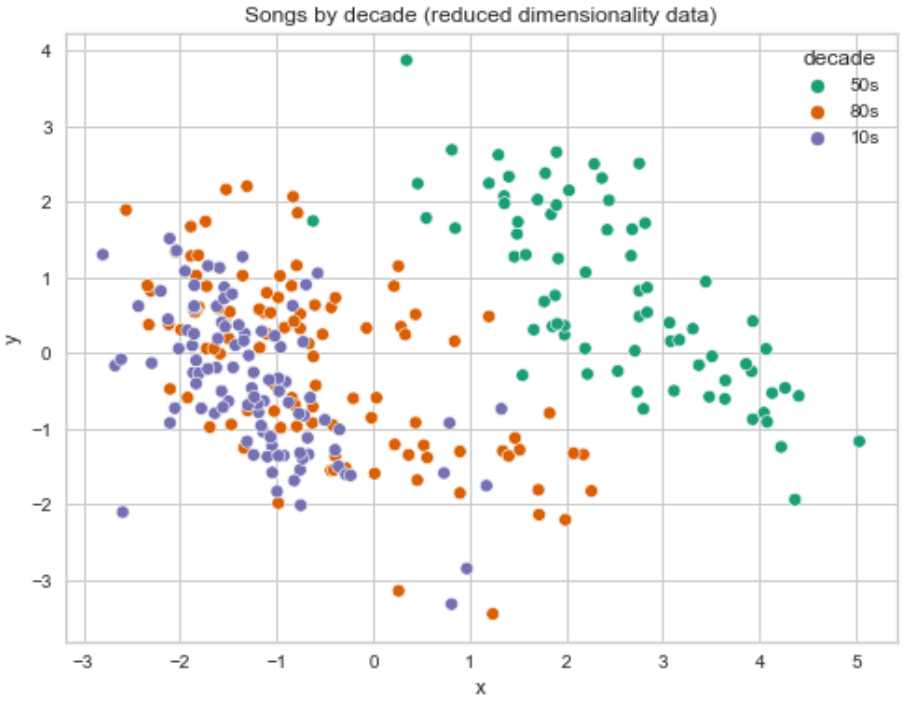

1 pav. Dimensijos sumažinimas naudojantis PCA metodu

3.2 Klasterizavimas k-means metodu

k-vidurkių metodas (angl. k-means) kiekvienam klasteriui apskaičiuoja centroidą (svorio centrą) ir kiekvieną objektą priskiria artimiausiam centroidui. Ši procedūra kartojama iki tol, kol tenkinamas sustojimo kriterijus. Centroidų (vadinasi ir klasterių) kiekis turi būti pasirenkamas iš anksto (1), (2). Centroidai įprastai inicializuojami atsitiktinai. Šis klasterizavimo metodas lengvai interpretuojamas, gali būti taikomas dideliems duomenų kiekiams, tačiau yra netinkamas neiškilių formų klasteriams identifikuoti. Prasti klasterizavimo rezultatai gaunami ir turint skirtingo dydžio, tankio ar dispersijos tikruosius klasterius.

Optimaliam klasterių skaičiui rasti alkūnės metodu visiems klasteriams suskaičiuojamos ir į bendrą sumą sudedamos Euklidinių atstumų nuo klasterio vidurkio taško kvadratų sumos (angl. within cluster sum of squares). Siekiant surasti optimalų klasterių skaičių nubraižoma šio gauto dydžio kreivė pagal klasterių skaičių k ir ieškoma linkio taško (angl. elbow point).

Naudojant šį metodą, originalios dimensijos duomenyse nematoma aiški linkio vieta (žr. 2 pav.), tuo tarpu sumažintos dimensijos duomenyse pastebimas šiek tiek ryškesnis linkis ties k=5 (žr. 3 pav.). Dėl šios priežasties pasirinkta k-means metodu klasterizuoti duomenis į 5 klasterius tiek originalios, tiek sumažintos dimensijos duomenyse. Rezultatai vizualizuoti naudojant sumažintos dimensijos duomenis su klasterių žymomis, gautomis k-means algoritmui pateikiant atitinkamai originalios ir sumažintos dimensijos duomenis.

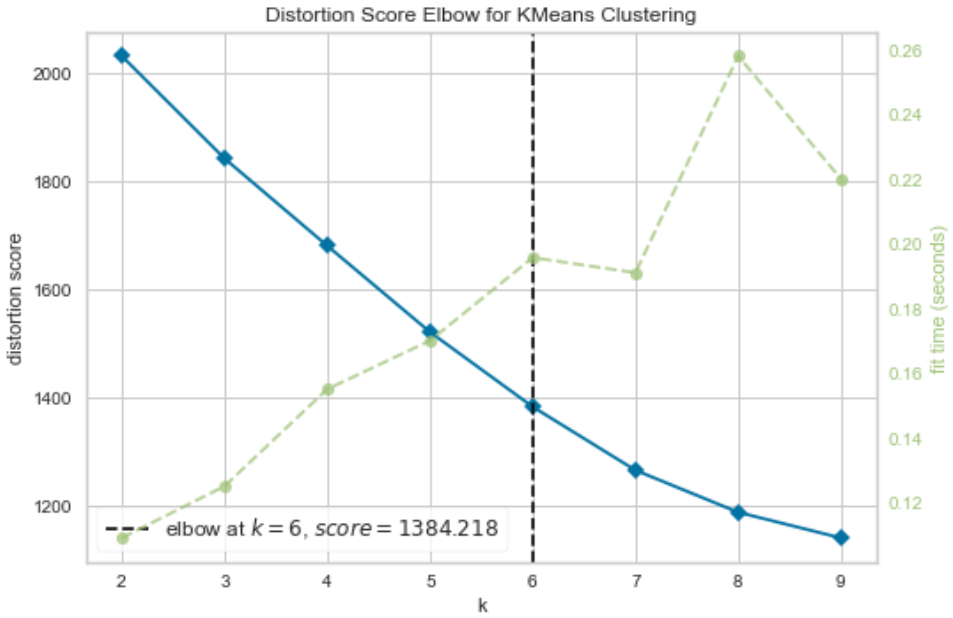

2 pav. Alkūnės (elbow) metodas originalios dimensijos duomenims

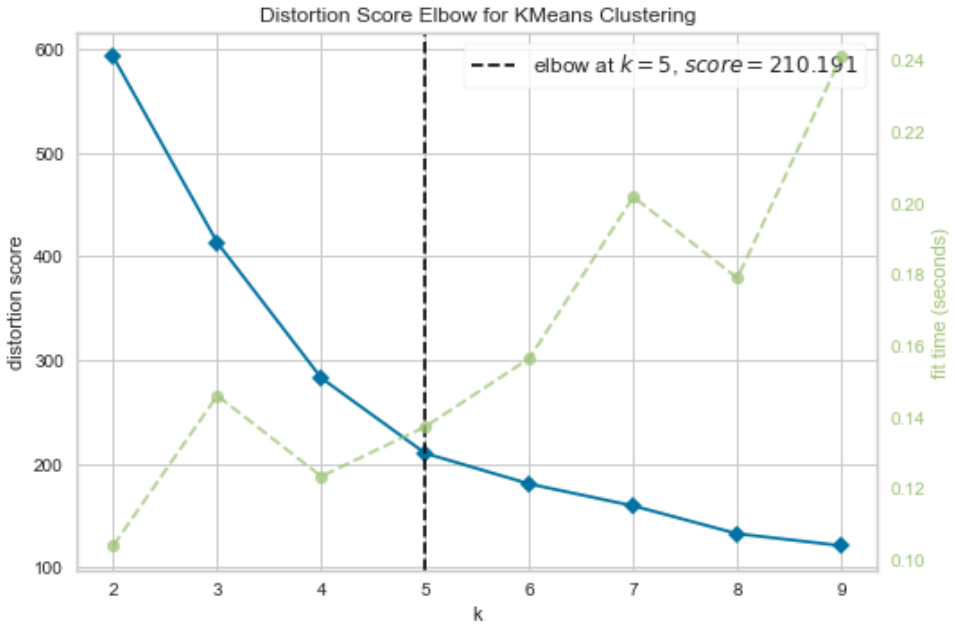

3 pav. Alkūnės (elbow) metodas sumažintos dimensijos duomenims

Originalios dimensijos duomenyse gauti klasteriai stipriai skiriasi nuo klasterių, gautų naudojant dimensijos mažinimo metodą, todėl klasteriai nėra stabilūs (žr. 4 pav.). Taip pat pastebėta, kad naudojant dimensijos mažinimą gaunami geresni klasterizavimo rezultatai - naudojant originalios dimensijos duomenis gaunamas itin mažas klasteris „0“, tačiau to yra išvengiama naudojant sumažintos dimensijos duomenis. Gautą geresnę klasterizavimo kokybę naudojant sumažintos dimensijos duomenis galime pamatyti ir silueto koeficiento reikšmių pasiskirstymo grafikuose (5 ir 6 pav.). Sumažintos dimensijos duomenyse klasterių dydžiai mažiau skiriasi tarpusavyje, silueto koeficiento reikšmės pasiskirsčiusios tolygiau.

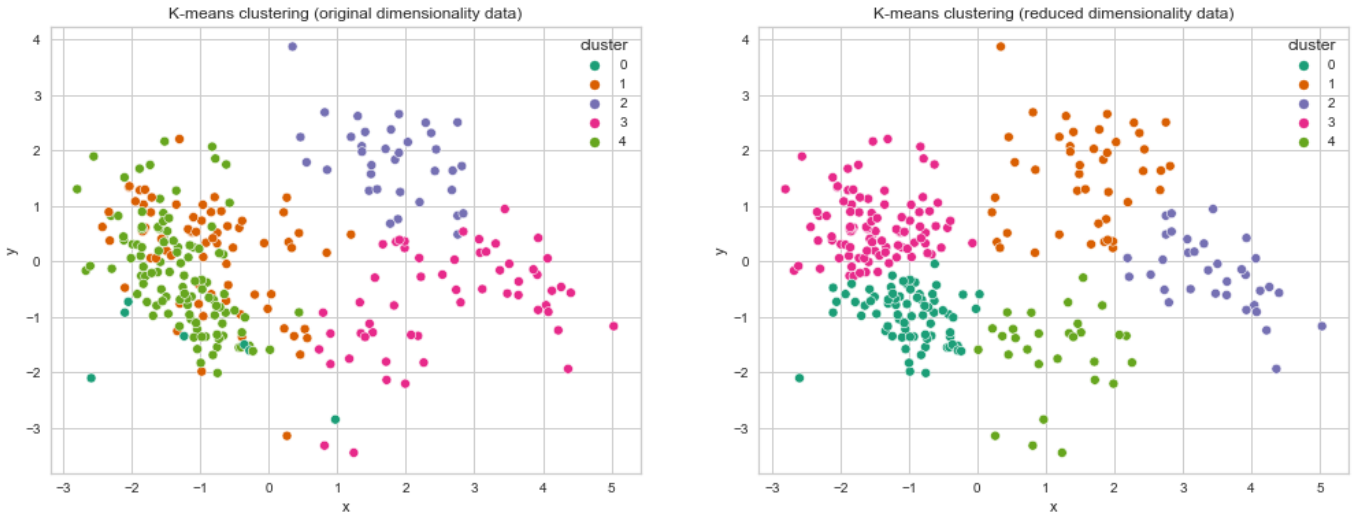

4 pav. 5 klasteriai originalios ir sumažintos dimensijos duomenyse

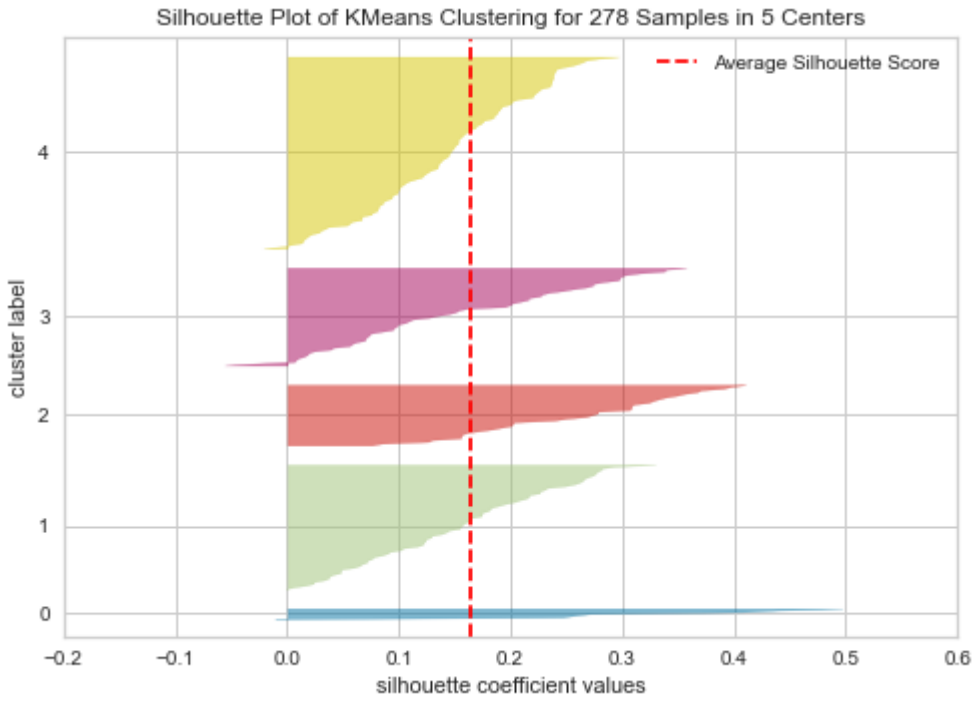

5 pav. Silueto koeficiento reikšmės originalios dimensijos duomenyse imant 5 klasterius

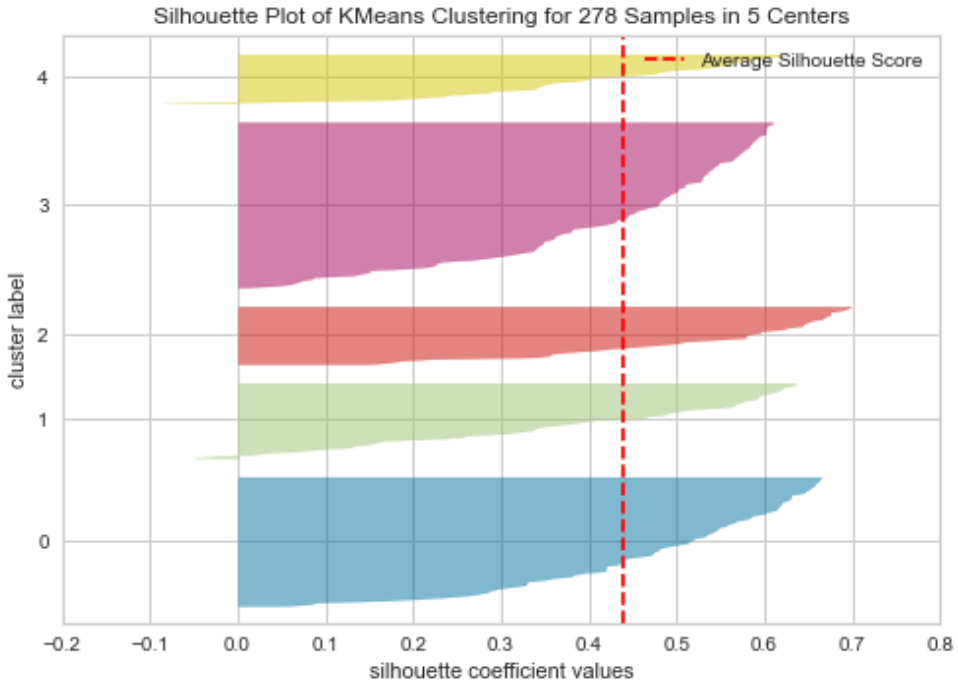

6 pav. Silueto koeficiento reikšmės sumažintos dimensijos duomenyse imant 5 klasterius

Lyginant sumažintos dimensijos duomenimis gautus klasterius pagal dainų išleidimo dešimtmetį rastos gana ryškios tendencijos (žr. 7 pav.). Klasteriams „1“ ir „2“ daugiausiai priklauso 50-ųjų dainos, tuo tarpu likusiems klasteriams priklauso 80-ųjų ir 2010-ųjų dainos.

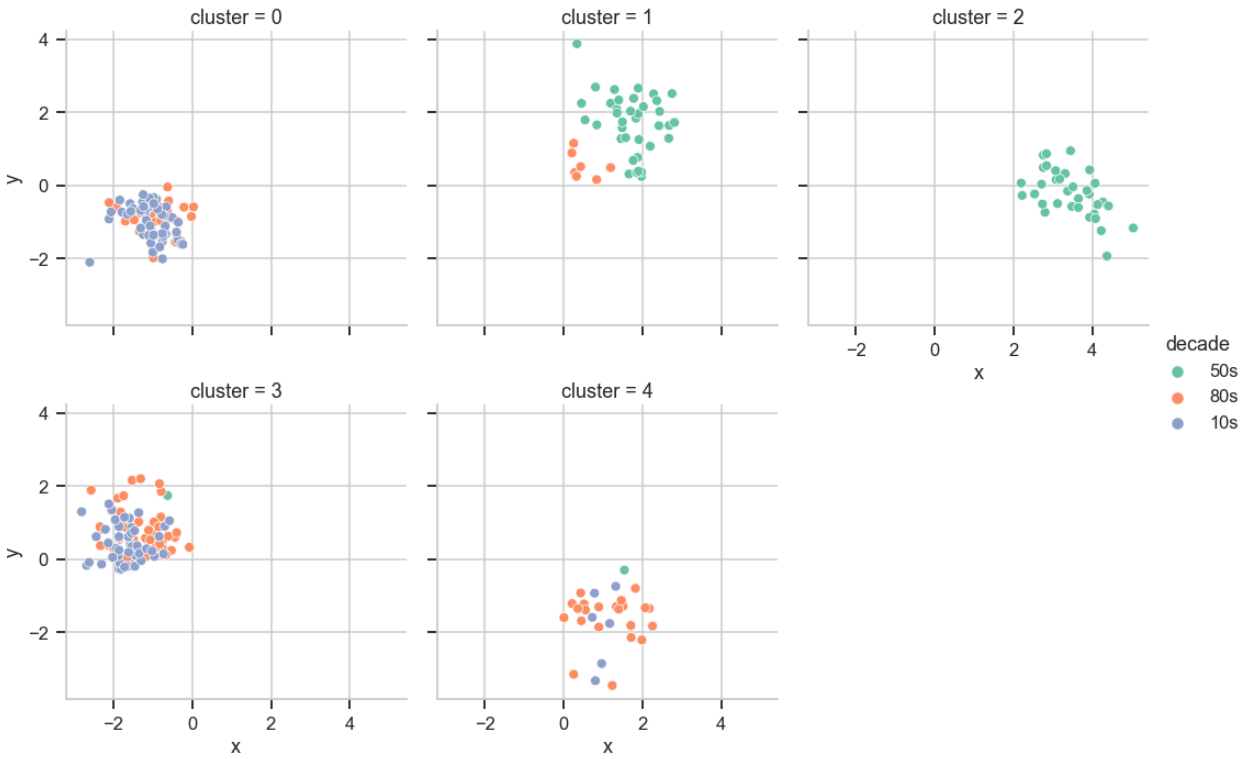

7 pav. Dainų dešimtmečiai pagal klasterį naudojant 5 klasterius

Silueto koeficientas lygina kiekvieno objekto panašumą su savo paties klasterio objektais lyginant su panašiausiu kito klasterio objektu. Optimalaus klasterių skaičiaus radimo metode, paremtame silueto koeficientais, kiekvienam klasterių skaičiui k skaičiuojamas vidutinis silueto koeficientas ir kaip optimalus klasterių skaičius pasirenkamas toks k, su kurio gaunama didžiausia šio dydžio reikšmė.

Tiek originalios, tiek sumažintos dimensijos duomenyse optimalus klasterių skaičius pagal vidutinį silueto koeficientą k = 2 (žr. 8 ir 9 pav.). Toks pat klasterių skaičius būtų pasirenkamas ir naudojantis empiriniu metodu, pagal kurį $k \approx \sqrt{\frac{n}{2}}$ (nes turima n=10, todėl $k \approx 2.23$).

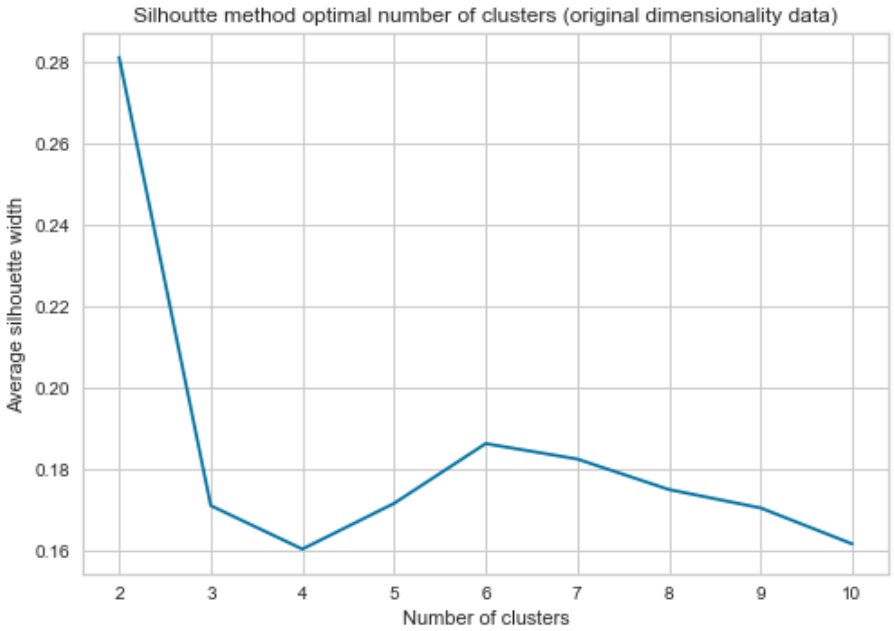

8 pav. Silueto metodas originalios dimensijos duomenims

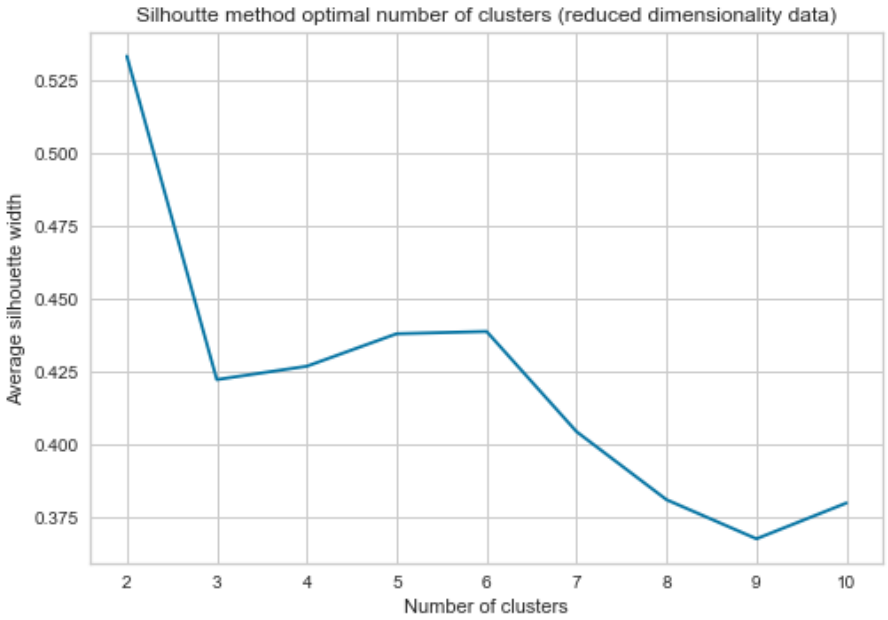

9 pav. Silueto metodas sumažintos dimensijos duomenims

Klasterizavimo kokybė vizualizuota vaizduojant individualių taškų silueto koeficiento reikšmių pasiskirstymą pagal klasterius (žr. 10 ir 11 pav.). Matoma, kad tik labai maža dalis taškų turi neigiamas silueto koeficiento reikšmes (yra išskirtys).

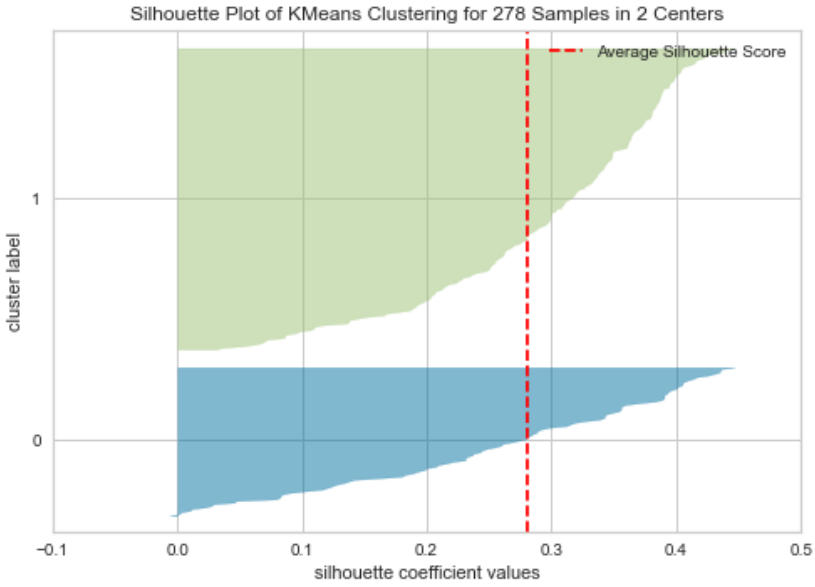

10 pav. Silueto koeficiento reikšmės originalios dimensijos duomenyse imant 2 klasterius

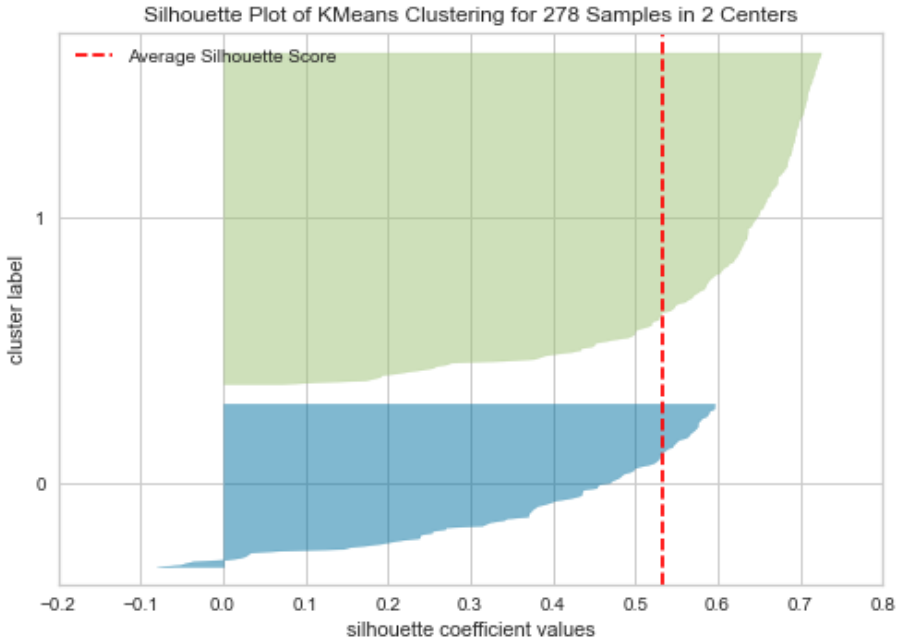

11 pav. Silueto koeficiento reikšmės sumažintos dimensijos duomenyse imant 2 klasterius

Gauti klasteriai stabilūs tarp originalios ir sumažintos dimensijos duomenų (skirtingas klasteris priskirtas tik vienam objektui) (žr. 12 pav.). Kadangi imant k=2 gaunami stabilūs klasteriai (be to šis klasterių skaičius gautas kaip optimalus naudojantis 2 iš 3 pasirinktų metodų), pasirinkta detaliau ištirti klasteriuose pasireiškiančias tendencijas imant šį klasterių skaičių.

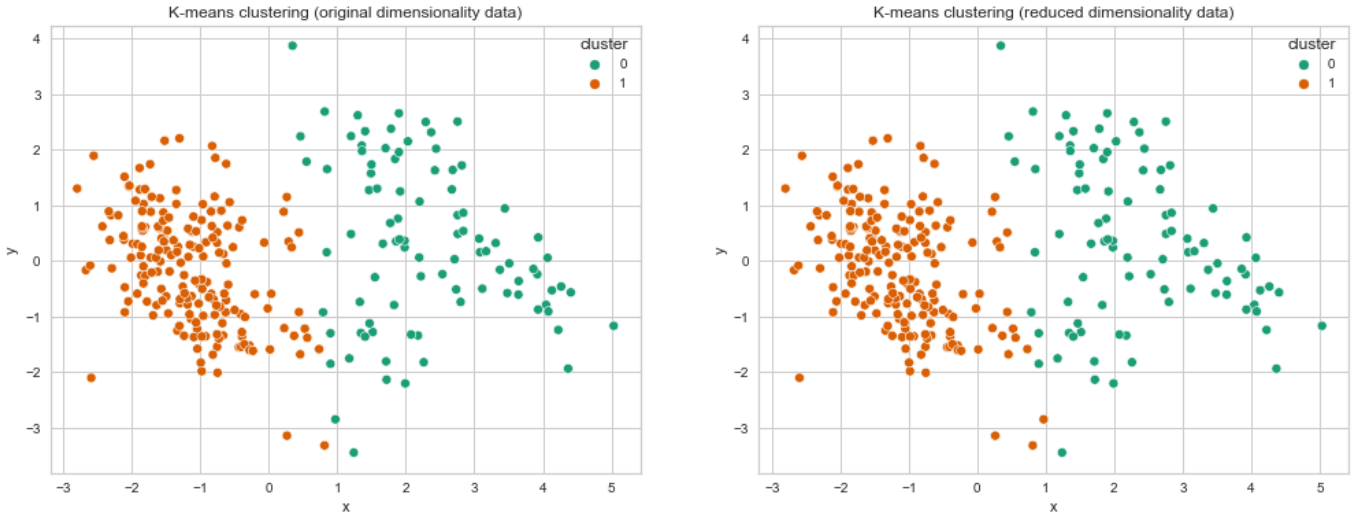

12 pav. 2 klasteriai originalios ir sumažintos dimensijos duomenyse naudojant k-means metodą

Skirtingų požymių reikšmių vidurkių ir medianos reikšmės pagal gautus klasterius pateiktos lentelėse (žr. 1 ir 2 lentelės).

1 lentelė Požymių reikšmių vidurkiai skirtinguose klasteriuose

„0“ originalios dimensijos duomenyse	„0“ sumažintos dimensijos duomenyse	„1“ originalios dimensijos duomenyse	„1“ sumažintos dimensijos duomenyse	Požymis
113.2	113.42	120.68	120.53	tempo
34.01	34.08	70.05	69.83	energy
51.24	51.26	64.98	64.9	danceability
-11.99	-11.98	-6.72	-6.75	loudness
16.66	16.74	17.79	17.75	liveness
51.96	52.33	57.46	57.25	valence
170.92	170.04	232.78	232.88	duration
70.6	70.62	15.52	15.8	acousticness
4.3	4.02	6.55	6.67	speechiness
46.93	46.56	71.89	71.94	popularity

2 lentelė Požymių reikšmių medianos reikšmės skirtinguose klasteriuose

„0“ originalios dimensijos duomenyse	„0“ sumažintos dimensijos duomenyse	„1“ originalios dimensijos duomenyse	„1“ sumažintos dimensijos duomenyse	Požymis
108.5	109.0	120.5	120.0	tempo
32.0	32.0	71.0	71.0	energy
51.0	51.0	67.0	67.0	danceability
-11.5	-11.0	-6.0	-6.0	loudness
13.0	13.0	12.0	12.0	liveness
49.0	50.0	56.0	56.0	valence
155.5	155.0	222.5	223.0	duration
74.0	75.0	11.0	11.0	acousticness
3.0	3.0	4.0	4.0	speechiness
44.0	44.0	72.0	72.0	popularity

Tiriant dainų išleidimo dešimtmečio pasiskirstymą pagal klasterius rasta, kad pirmajame klasteryje dominuoja 50-ųjų dainos, tuo tarpu antrajame – 80-ųjų ir 2010-ųjų dainos (žr. 13 pav.).

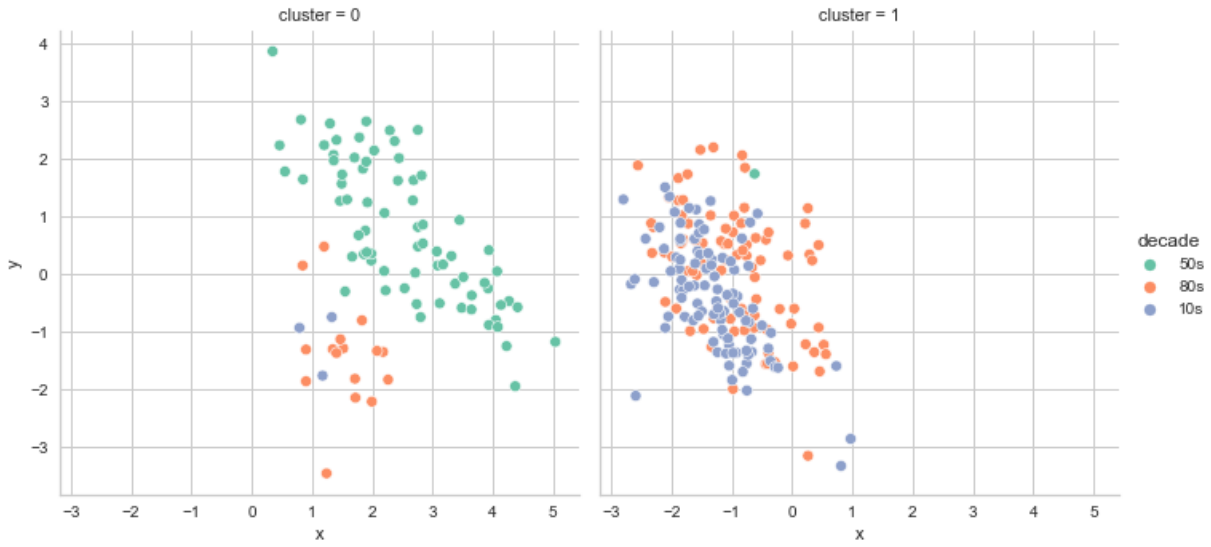

13 pav. Dainų dešimtmečiai pagal klasterį naudojant 2 klasterius

Lyginant klasterius pagal skaitinius požymius rasta, kad tiek pagal medianą, tiek pagal vidurkį, antrajam klasteriui priklauso žemo akustiškumo, didelės energijos ir didelio populiarumo dainos lyginant su pirmuoju klasteriu (žr. 14, 15 ir 16 pav.).

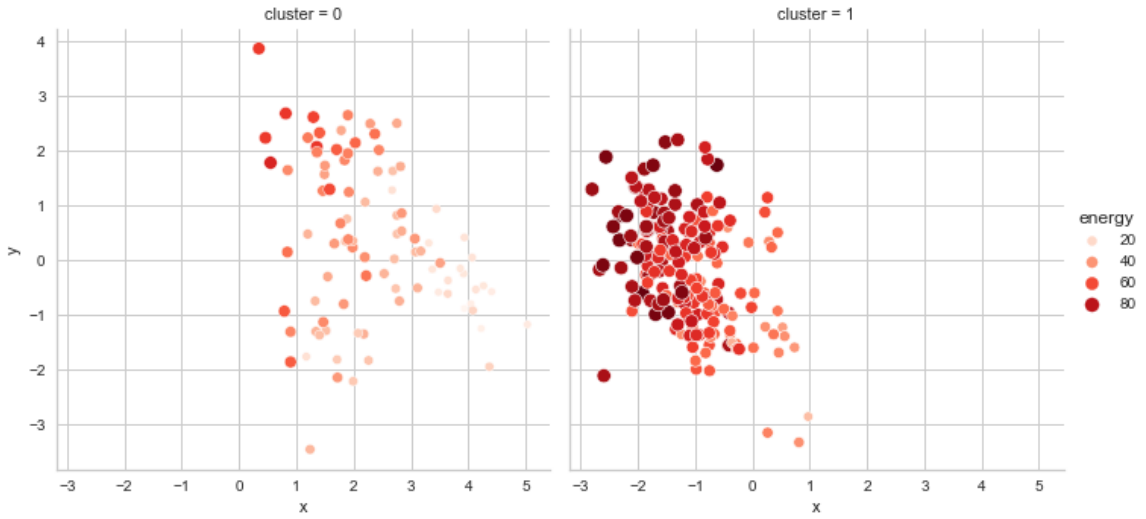

14 pav. Dainų energija pagal klasterį

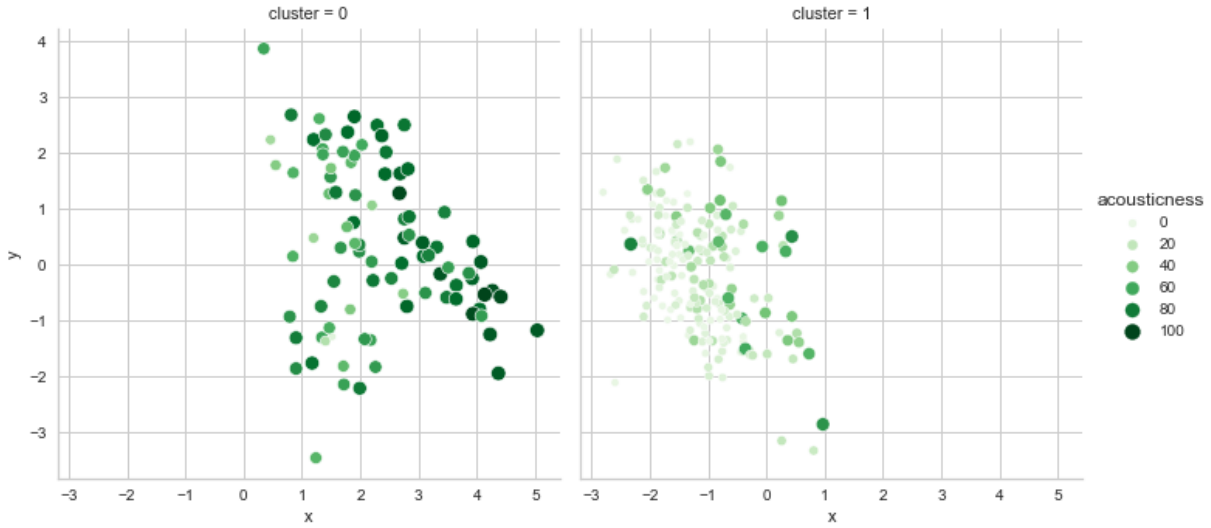

15 pav. Dainų akustiškumas pagal klasterį

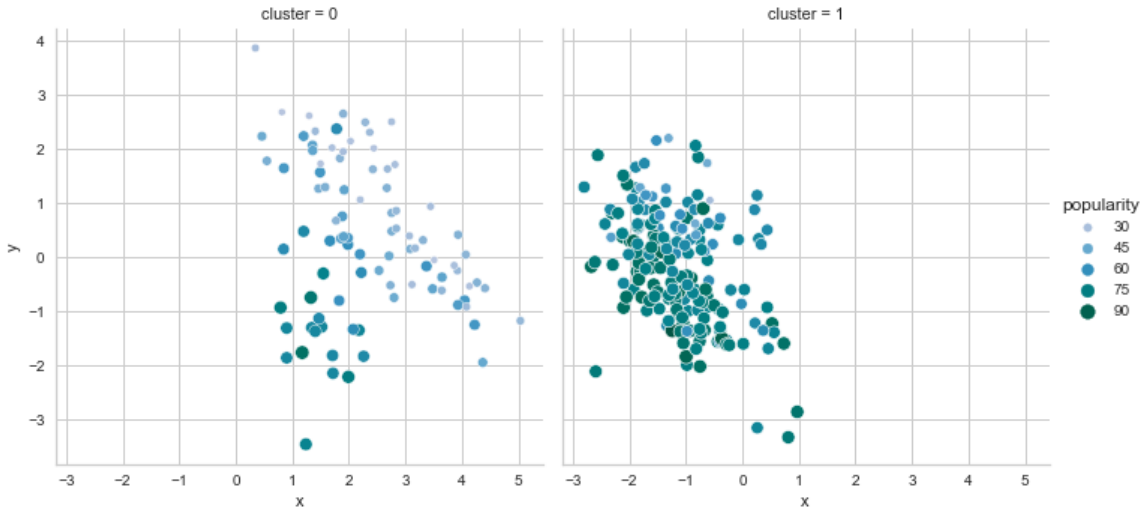

16 pav. Dainų populiarumas pagal klasterį

3.3 Klasterizavimas *DBSCAN* metodu

DBSCAN yra tankiu paremtas klasterizavimo metodas, kuriame klasteriai apibrėžiami kaip didžiausia duomenų aibė, sudaryta iš pagal tam tikrus tankio kriterijus sujungtų taškų (3). Šis metodas gali aptikti bet kokios formos klasterius, susidoroja su triukšmu, tačiau algoritmo rezultatus labai stipriai įtakoja pasirinkti parametrai. Pirmas parametras yra maksimalus paieškos atstumas nuo nepriskirto taško *eps*, kuris yra atsakingas už paieškos apskritimo dydį. Kitas parametras *MinPts* yra minimalus kaimynų, kurie yra artimi nepriskirtam taškui apskritimo aplinkoje, skaičius.

MinPts parametrą pasirinkta parinkti naudojantis taisykle *MinPts* = 2n, kur n – duomenų aibės požymių skaičius. Originalios ir sumažintos dimensijos duomenims *MinPts* reikšmės gautos lygios atitinkamai 20 ir 4.

Parametras *eps* parinktas kiekvienam objektui apskaičiuojant atstumą iki *MinPts*-ojo artimiausio taško, šias reikšmes išrūšiuojant didėjimo tvarka ir vizualiai ieškant kelio (angl. knee) taško grafike. Šio parametro optimalios reikšmės gautos lygios atitinkamai 3.5 ir 0.7 (žr. 17 ir 18 pav.).

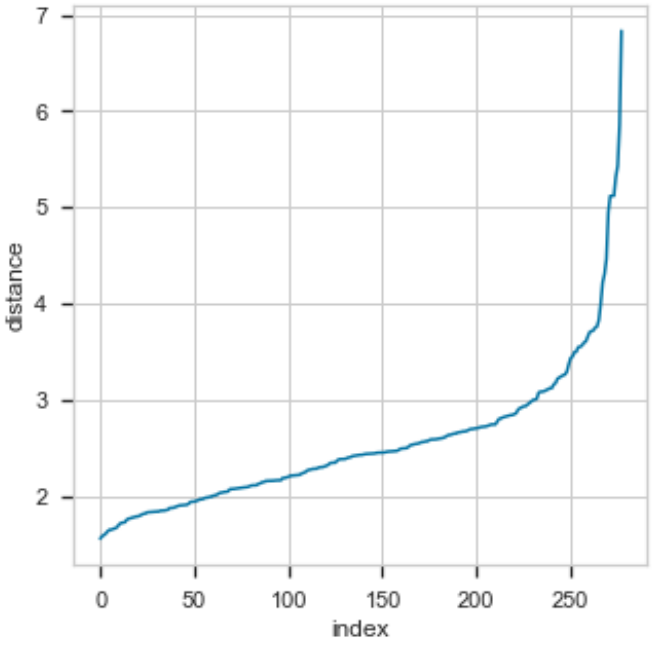

17 pav. eps parametro parinkimas originalios dimensijos duomenims

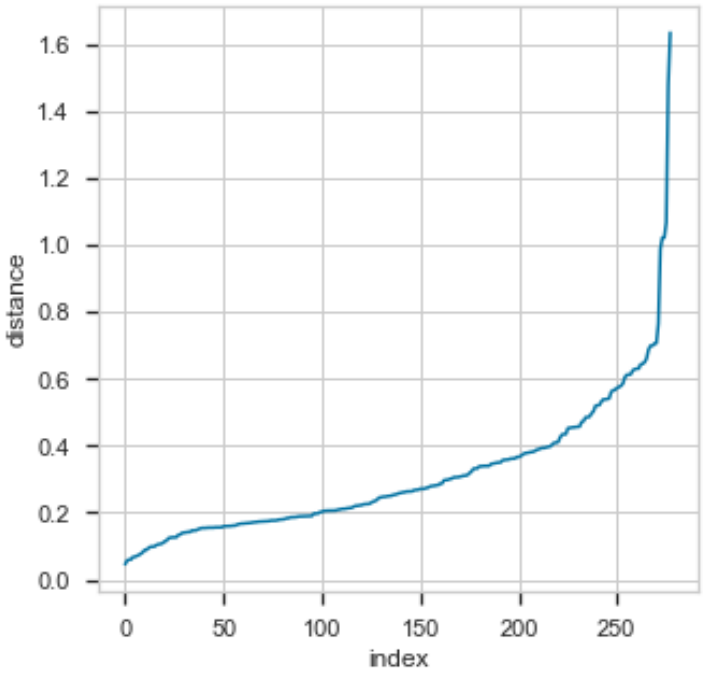

18 pav. eps parametro parinkimas sumažintos dimensijos duomenims

Naudojant DBSCAN metodą su prieš tai aprašytais parametrais negauti prasmingi rezultatai (žr. 19 pav.). Su originalios dimensijos duomenimis beveik visi taškai priskirti vienam klasteriui, likę taškai laikyti triukšmo taškais. Tuo tarpu sumažintos dimensijos duomenyse visi taškai priskirti triukšmo taškams. Dėl šių priežasčių pasirinkta laikyti, kad naudojant DBSCAN metodą prasmingų įžvalgų apie turimą duomenų aibę nebuvo gauta.

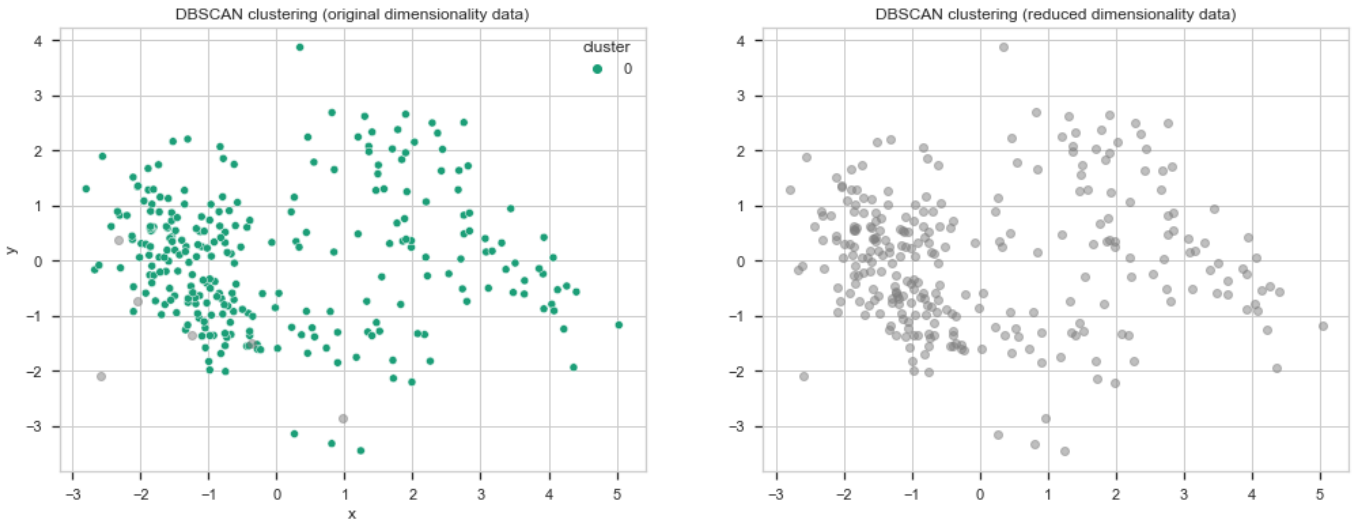

19 pav. Klasteriai originalios ir sumažintos dimensijos duomenyse naudojant DBSCAN metodą

3.4 Klasterizavimas hierarchiniu metodu

Hierarchinis klasterizavimo metodai galutinius klasterius sudaro pakartotinai sujungdamas (arba išskaidydamas) prieš tai turimus klasterius. Ši klasterių hierarchija vizualizuojama dendrograma.

Naudojant hierarchinį jungimo metodą (angl. agglomerative) pirmiausia tarp visų duomenų aibės objektų apskaičiuojama atstumų matrica. Pradžioje laikoma, kad kiekvienas objektas sudaro atskirą klasterį. Pagal pasirinktą jungimo matą sujungiami du panašiausi objektai ir iš naujo perskaičiuojama atstumų matrica. Ši procedūra kartojama iki tol, kol gaunamas vienas bendras klasteris (4). Šiam metodui nereikia iš anksto žinoti klasterių kiekio, jis įprastai pasirenkamas naudojantis dendrograma.

Pasirinkta naudoti Ward jungimo matą, nes taip gautas labiausiai pagal sujungiamų klasterių dydžius subalansuotas jungimas. Naudojantis dendrogramomis tiek originalios, tiek sumažintos dimensijoms duomenims pasirinkta duomenų aibę dalinti į dvi dalis. (žr. 20 ir 21 pav.).

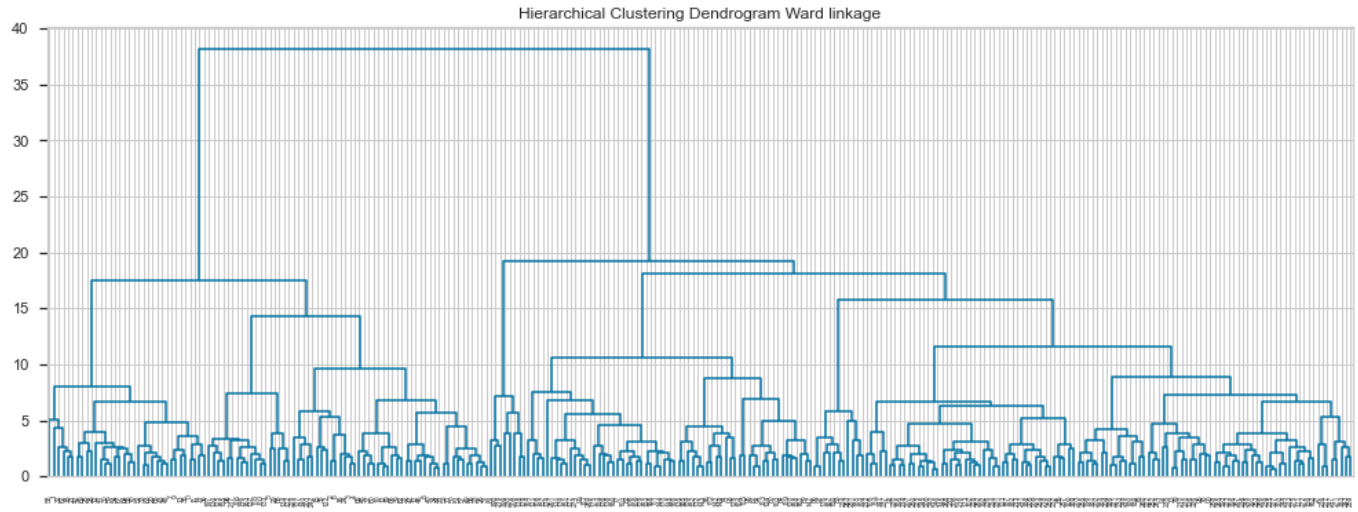

20 pav. Klasterizavimo dendrograma naudojant Ward jungimo matą originalios dimensijos duomenims

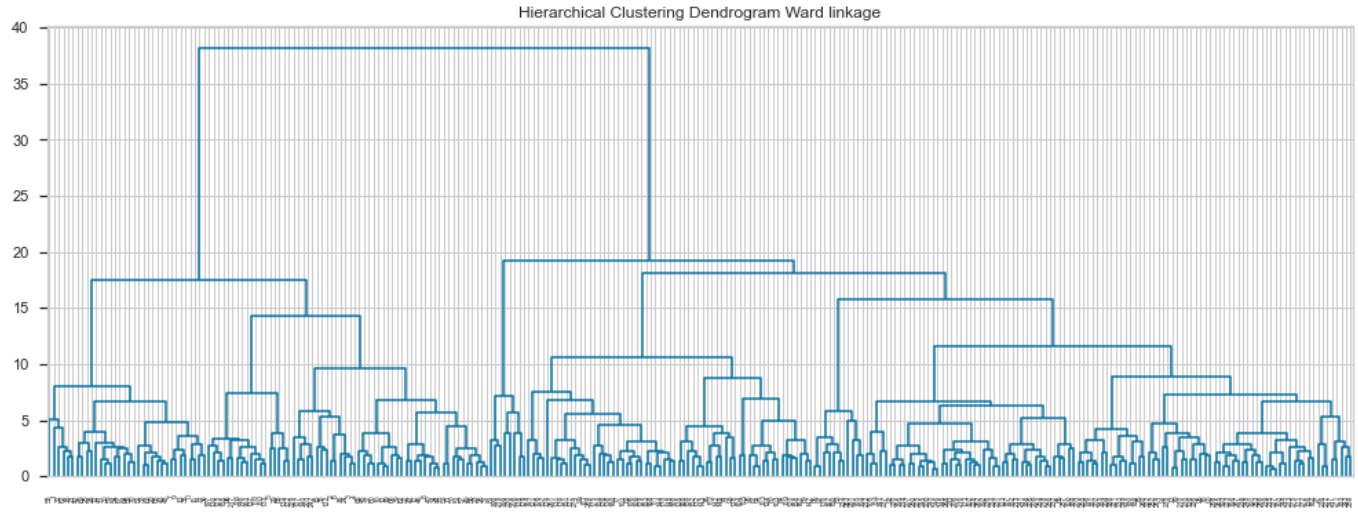

21 pav. Klasterizavimo dendrograma naudojant Ward jungimo matą sumažintos dimensijos duomenims

Gauti klasteriai stabilūs, be to beveik visiems objektams priskirtas toks pat klasteris kaip gauta naudojant k-means metodą pasirinkus k=2 (žr. 22 pav.). Dėl šios priežasties daroma prielaida, kad klasteriuose galioja tos pačios požymių tendencijos apibūdintos ankščiau.

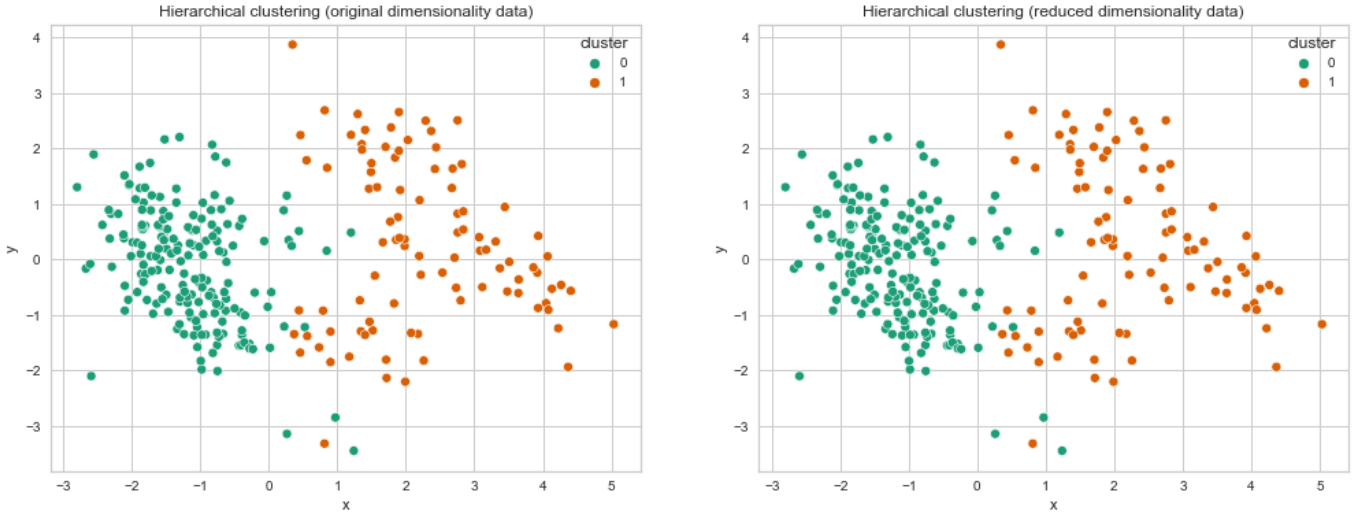

22 pav. 2 klasteriai originalios ir sumažintos dimensijos duomenyse naudojant hierarchinį klasterizavimą

4 Išvados

Duomenų aibę sudaro skirtingų dešimtmečių dainos su skaitiniais požymiais apie šias dainas. Duomenys standartizuoti ir pasirinkta klasterizavimui naudoti visus skaitinius požymius (n=10). Siekiant palyginti klasterizavimo rezultatus gautus naudojant dimensijos mažino metodus ir jų nenaudojant, klasterizavimui naudojamų požymių dimensija sumažinta iki 2 naudojant PCA metodą.

Naudojant k-vidurkių (angl. k-means) algoritmą, klasterių skaičius naudojantis alkūnės metodu negautas vienareikšmiškai aiškus. Naudojant vieną iš galimų reikšmių k=5 gauti nestabilūs klasteriai – duomenų aibės objektų priskyrimas klasteriams stipriai skiriasi naudojant sumažintos dimensijos duomenis. Tarta, kad jeigu pasirenkamas šis klasterių skaičius, tai sumažinus požymių dimensiją gaunami geresni klasterizavimo rezultatai. Sumažintos dimensijos duomenimis gautuose klasteriuose rastos tendencijos objektams priklausyti tam tikram klasteriui pagal dainų išleidimo dešimtmečius.

Optimalus klasterių skaičius naudojantis empiriniu ir vidutinio silueto metodais gautas k=2. Šie klasteriai išlieka stipriai stabilūs imant originalios ir sumažintos dimensijos duomenis (skirtingas klasteris priskirtas tik vienam duomenų aibės objektui), todėl pasireiškiančios požymių tendencijos šiuose klasteriuose ištirtos detaliau.

Lyginant kokios tendencijos išryškėja sudarytuose klasteriuose rasta, kad didžioji dalis pirmajam klasteriui priklausančių dainų yra išleistos 50-aisias, tuo tarpu antrajam klasteriui priklauso beveik vien tik 80-ųjų ir 2010-ųjų dainos. Pastebėta išryškėjusi tendencija, kad antrajam klasteriui priklausančios dainos yra stipriai mažiau akustiškos, tačiau didesnės energijos ir didesnio populiarumo negu dainos, priklausančios pirmajam klasteriui. Antrajam klasteriui priklausančios dainos taip pat yra vidutiniškai ilgesnės, garsesnės, labiau tinkamos šokti, greitesnio tempo, tačiau šios tendencijos nėra tokios ryškios kaip minėtos prieš tai.

DBSCAN algoritmui pagal nykščio taisykles parinkus optimalias parametrų $MinPts$ ir eps reikšmes, naudojant originalios dimensijos duomenis beveik visi taškai priskirti vienam klasteriui, tuo tarpu su sumažintos dimensijos duomenimis visi objektai buvo priskirti triukšmo taškams. Dėl šių priežasčių laikyta, kad naudojant DBSCAN metodą prasmingų įžvalgų apie turimą duomenų aibę nebuvo gauta.

Naudojant hierarchinį klasterizavimą geriausi rezultatai gauti su Ward jungimo matu. Pagal dendrogramą pasirinkta duomenų aibę dalinti į dvi dalis tiek su originalios, tiek su sumažintos dimensijos duomenimis. Gauti stabilūs klasteriai, beveik visiems duomenų aibės objektams priskirtas toks pat klasteris kaip ir naudojant k-means metodą su k=2, todėl laikyta, kad naudojant ir šį metodą išlieką prieš tai aprašytos tendencijos klasteriuose.

5 Šaltiniai

1. *The k-means Algorithm: A Comprehensive Survey and Performance Evaluation.* **M. Ahmed, R. Seraj, S. Islam.** 2020 m., Electronics.

2. *A Clustering Method Based on K-Means Algorithm.* **L. Youguo, W. Haiyan.** 2012 m., Physics Procedia, T. 25, p. 1104-1109.

3. *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise.* **M. Ester, H. Kriegel, J. Sander.** 1996 m., Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, p. 226-231.

4. *Methods of Hierarchical Clustering.* **F. Murtagh, P. Contreras.** 2011 m., Computing Research Repository.

Priedas

Žemiau pateiktas naudotas programinis kodas:

```
# #### Read-in the data

import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns


def read_clean_data(filename):
    df  =  pd.read_csv(filename)[['title','artist','year','bpm',  'nrgy',  'dnce',  'dB','live',  'val',
'dur','acous', 'spch','pop']]
    df                                                                                                  =
df.rename({'bpm':'tempo','nrgy':'energy','dnce':'danceability','dB':'loudness','live':'liveness',

'val':'valence','dur':'duration','acous':'acousticness','spch':'speechiness','pop':'popularity'},
                  axis = 1)
    df['decade'] = filename[2:4] + 's'
    return df

from sklearn.preprocessing import StandardScaler

filenames = ['1950.csv','1980.csv','2010.csv']

df = pd.concat([read_clean_data(i) for i in filenames]).reset_index()
df_id = df[["title","artist","decade"]]
df = df.iloc[:,4:len(df.columns)-1]

# pozymiai, pagal kuriuos klasteriuojama
df.describe().T.drop("count",axis=1)

x = StandardScaler().fit_transform(df)

from sklearn.cluster import KMeans, AgglomerativeClustering, DBSCAN
from sklearn.manifold import MDS
from sklearn.decomposition import PCA

def do_mds(x,n_components=2,**kwargs):
    mds = MDS(n_components,**kwargs)
    x_trans = mds.fit_transform(x)
    return x_trans


def do_pca(x,n_components=2,**kwargs):
    pca = PCA(n_components,**kwargs)
    x_trans = pca.fit_transform(x)
    return x_trans

# klasterizavimas originaliems duomenims ir sumazinus dimensija
x_small = do_pca(x,n_components=2)

df_plot = pd.DataFrame(do_pca(x))
df_plot.columns = ["x","y"]

fig, ax = plt.subplots(1,1,figsize=(8, 6))
plot = sns.scatterplot(x="x",y="y",hue=df_id["decade"],data=df_plot,palette="Dark2",ax=ax)
```

```
plot.set_title("K-means clustering (reduced dimensionality data)")


# #### KMeans

def do_kmeans(x, standartize = True,**kwargs):

    model = KMeans(**kwargs)
    pred = model.fit_predict(x)
    return pred, model

from yellowbrick.cluster import SilhouetteVisualizer, KElbowVisualizer

visualizer = KElbowVisualizer(KMeans(), k=(2,10))

visualizer.fit(x)
visualizer.show()

visualizer = KElbowVisualizer(KMeans(), k=(2,10))

visualizer.fit(x_small)
visualizer.show()

silhouette_scores = []
for i in list(range(2,11)):
    model = KMeans(i)
    visualizer = SilhouetteVisualizer(model, colors='yellowbrick')
    visualizer.fit(x)
    silhouette_scores.append(visualizer.silhouette_score_)

plt.clf()
plt.plot(range(2,11),silhouette_scores)
plt.title("Silhoutte method optimal number of clusters (original dimensionality data)")
plt.xlabel("Number of clusters")
plt.ylabel("Average silhouette width")

silhouette_scores = []
for i in list(range(2,11)):
    model = KMeans(i)
    visualizer = SilhouetteVisualizer(model, colors='yellowbrick')
    visualizer.fit(x_small)
    silhouette_scores.append(visualizer.silhouette_score_)

plt.clf()
plt.plot(range(2,11),silhouette_scores)
plt.title("Silhoutte method optimal number of clusters (reduced dimensionality data)")
plt.xlabel("Number of clusters")
plt.ylabel("Average silhouette width")


for i in [2,5]:
    model = KMeans(i,random_state=123)
    visualizer = SilhouetteVisualizer(model, colors='yellowbrick')

    visualizer.fit(x)
    visualizer.show()

for i in [2,5]:
    model = KMeans(i,random_state=123)
    visualizer = SilhouetteVisualizer(model, colors='yellowbrick')
```

```
    visualizer.fit(x_small)
    visualizer.show()

# elbow metodas
fig, ax = plt.subplots(1,2,figsize=(17, 6))
ax = ax.flatten()
df_plot["cluster"], _ = do_kmeans(x,n_clusters=5,random_state=123)
plot = sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot,palette="Dark2",ax=ax[0])
plot.set_title("K-means clustering (original dimensionality data)")

df_plot["cluster"], _ = do_kmeans(x_small,n_clusters=5,random_state=123)
plot = sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot,palette="Dark2",ax=ax[1])
plot.set_title("K-means clustering (reduced dimensionality data)")

# kuo skiriasi klasteriai pagal desimtmecius
sns.set_context("talk")
df_plot["decade"] = df_id["decade"]
sns.relplot(x="x",y="y",kind="scatter",data=df_plot,col="cluster",hue="decade",palette="Set2",col_wrap=
3)

# silhouette metodas
sns.set_context("notebook")
fig, ax = plt.subplots(1,2,figsize=(17, 6))
ax = ax.flatten()
df_plot["cluster"], _ = do_kmeans(x,n_clusters=2,random_state=123)
df["cluster_original"] = df_plot["cluster"]
plot = sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot,palette="Dark2",ax=ax[0])
plot.set_title("K-means clustering (original dimensionality data)")


df_plot["cluster"], _ = do_kmeans(x_small,n_clusters=2,random_state=123)
df["cluster_reduced"] = df_plot["cluster"]
plot = sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot,palette="Dark2",ax=ax[1])
plot.set_title("K-means clustering (reduced dimensionality data)")

def statistics(df):
    statistics_1 = df.groupby("cluster_original").describe().T
    statistics_1 = statistics_1.reset_index()[statistics_1.reset_index()["level_1"].isin(["50%"])]
    columns = list(statistics_1.columns)
    columns[0] = "variable"
    columns[1] = "statistic"
    for i in range(2,len(columns)):
        columns[i] = str(columns[i]) + "_original"
    statistics_1.columns = columns

    statistics_2 = df.groupby("cluster_reduced").describe().T
    statistics_2 = statistics_2.reset_index()[statistics_2.reset_index()["level_1"].isin(["50%"])]
    columns = list(statistics_2.columns)
    columns[0] = "variable"
    columns[1] = "statistic"
    for i in range(2,len(columns)):
        columns[i] = str(columns[i]) + "_reduced"
    statistics_2.columns = columns

    statistics =  statistics_1.merge(statistics_2,how="inner")

    statistics = statistics.reindex(sorted(statistics.columns), axis=1)

    return statistic

# klasteriu palyginimas
```

```
print(df["cluster_original"].value_counts())
print(df["cluster_reduced"].value_counts())

statistics(df)

# kuo skiriasi klasteriai pagal desimtmecius
df_plot["decade"] = df_id["decade"]
sns.relplot(x="x",y="y",kind="scatter",data=df_plot,col="cluster",hue="decade",palette="Set2")

df_plot["energy"] = df["energy"]
sns.relplot(x="x",y="y",kind="scatter",hue="energy",size="energy",data=df_plot,col="cluster",palette="R
eds")

df_plot["acousticness"] = df["acousticness"]
sns.relplot(x="x",y="y",kind="scatter",hue="acousticness",size="acousticness",data=df_plot,col="cluster
",palette="Greens",hue_norm = (-10,100))

df_plot["popularity"] = df["popularity"]
sns.relplot(x="x",y="y",kind="scatter",hue="popularity",size="popularity",data=df_plot,col="cluster",pa
lette="PuBuGn",
            hue_norm = (-10,100))


# #### Hierarchical

def do_hierarchical(df, standartize = True,**kwargs):
    model =  AgglomerativeClustering(**kwargs)
    pred = model.fit_predict(x)

    return pred, model

from scipy.cluster.hierarchy import dendrogram

def plot_dendrogram(model, **kwargs):
    counts = np.zeros(model.children_.shape[0])
    n_samples = len(model.labels_)
    for i, merge in enumerate(model.children_):
        current_count = 0
        for child_idx in merge:
            if child_idx < n_samples:
                current_count += 1  # leaf node
            else:
                current_count += counts[child_idx - n_samples]
        counts[i] = current_count

    linkage_matrix = np.column_stack(
        [model.children_, model.distances_, counts]
    ).astype(float)
    fig, ax = plt.subplots(1,1,figsize=(17, 6))
    dendrogram(linkage_matrix, **kwargs, ax = ax)

_, model = do_hierarchical(x,distance_threshold=0, n_clusters=None,linkage="ward")

plot_dendrogram(model, color_threshold=0)
plt.title("Hierarchical Clustering Dendrogram Ward linkage")

_, model = do_hierarchical(x_small,distance_threshold=0, n_clusters=None,linkage="ward")

plot_dendrogram(model, color_threshold=0)
plt.title("Hierarchical Clustering Dendrogram Ward linkage")
```

```
fig, ax = plt.subplots(1,2,figsize=(17, 6))
ax = ax.flatten()
df_plot["cluster"], _ = do_hierarchical(x,n_clusters=2,linkage="ward")
df["cluster_original"] = df_plot["cluster"]
plot = sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot,palette="Dark2",ax=ax[0])
plot.set_title("Hierarchical clustering (original dimensionality data)")

df_plot["cluster"], _ = do_hierarchical(x_small,n_clusters=2,linkage="ward")
df["cluster_reduced"] = df_plot["cluster"]
plot = sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot,palette="Dark2",ax=ax[1])
plot.set_title("Hierarchical clustering (reduced dimensionality data)")


# #### DBSCAN

from sklearn.neighbors import NearestNeighbors
def do_dbscan(df, **kwargs):
    model = DBSCAN(**kwargs)
    pred = model.fit_predict(x)

    return pred, model

x.shape, x_small.shape

nn=NearestNeighbors(n_neighbors=20).fit(x)

distances, indices = nn.kneighbors(x)
farthest = distances[:,-1]

fig, ax = plt.subplots(1,1,figsize=(5, 5))
plt.plot(np.sort(farthest))
plt.xlabel("index")
plt.ylabel("distance")
plt.show()

# #####  Originaliam duomenų rinkiniui: minSamples = 2n = 20 , eps = 3.5

nn=NearestNeighbors(n_neighbors=min_samples_small).fit(x_small)

distances, indices = nn.kneighbors(x_small)
farthest = distances[:,-1]

fig, ax = plt.subplots(1,1,figsize=(5, 5))
plt.plot(np.sort(farthest))
plt.xlabel("index")
plt.ylabel("distance")
plt.show()

# #####  Sumažintos dimensijos duomenų rinkiniui: minSamples = 4, eps = 0.7

fig, ax = plt.subplots(1,2,figsize=(17, 6))
ax = ax.flatten()
df_plot["cluster"], _ = do_dbscan(x,min_samples=20,eps=3.5)
df_noise = df_plot[df_plot["cluster"]==-1]
plot           =           sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot[df_plot["cluster"]!=-
1],palette="Dark2",ax=ax[0])
plot.scatter(df_noise["x"],df_noise["y"],c="grey",alpha=0.5)
plot.set_title("DBSCAN clustering (original dimensionality data)")

df_plot["cluster"], _ = do_dbscan(x_small,min_samples=4,eps=0.7)
df_noise = df_plot[df_plot["cluster"]==-1]
```

```
plot           =           sns.scatterplot(x="x",y="y",hue="cluster",data=df_plot[df_plot["cluster"]!=-
1],palette="Dark2",ax=ax[1])
plot.scatter(df_noise["x"],df_noise["y"],c="grey",alpha=0.5)
plot.set_title("DBSCAN clustering (reduced dimensionality data)")
```